

# Deep Learning in Biomedical Optical Imaging

## HW4

張晉綸 113003813

### 1.1 Task A: Model Selection (20%)

In this task, you will explore various pre-trained models available in *torchvision.models*, select two models, and justify their choices. The focus will be on understanding the architecture, their pre-trained performances, and predicting their adaptability to new tasks via transfer learning.

**Model Choice (5%):** List the two pre-trained models you have selected for the transfer learning tasks.

1. ResNet50
2. EfficientNet B0

**Explanation (15%):** The explanation should encompass a range of aspects including, but not limited to, the complexity of the architecture, the performance of the models when pre-trained, and their computation time for the transfer learning tasks.

**ResNet** (Residual Network) 因其經典的深度神經網絡架構，特別適合在影像分類中表現穩定。在醫學影像分析中，**ResNet** 的預訓練模型能快速收斂，對於灰階的 X 光片也能適當地提取邊緣和結構特徵，達到較高的分類準確率。

**EfficientNet** 是一個計算高效的模型，在保持高準確率的同時顯著降低了計算資源需求，特別適合高解析度影像和資源有限的情境。

**EfficientNet** 的預訓練模型在 **ImageNet** 等大型數據集上達到了高準確率，非常適合醫學影像分類這類需要高效處理的任務。

以下再分析模型的細節：

#### 1. 模型架構的複雜度

**ResNet**：ResNet (Residual Network) 的架構相對簡單但有效，它採用殘差塊 (Residual Blocks)，通過引入「跳接連結」(skip connections) 來解決深層網絡中的梯度消失問題。這樣的架構允許 ResNet 擁有更多層數 (如 ResNet-50 或 ResNet-101)，而不會大幅

增加訓練難度。對於醫學影像分類，**ResNet** 可以在增加網絡深度的同時保持穩定性，因此適合處理更具複雜性的 X 光照片。

**EfficientNet**：EfficientNet 則使用了一種稱為 複合縮放（Compound Scaling）的方法，同時擴展網絡的深度、寬度和解析度，以達到最佳平衡。這使得它在相對較少的參數下達到了更高的性能。

EfficientNet 的架構雖然複雜，但計算效率高，適合資源受限的環境，且可以有效應用於醫學影像，尤其是在影像解析度較高的任務中。

## 2. 預訓練模型的性能

**ResNet**：ResNet 在 ImageNet 等大型數據集上訓練時，已展現了穩定的分類準確率，並且在 Transfer Learning 任務中常常被用作基礎模型。在醫學影像分析領域，ResNet 的預訓練模型通常能快速收斂，對於胸腔 X 光照片這類灰階影像，也能夠適當地提取邊緣、結構等特徵，達到較高的分類準確率。

**EfficientNet**：EfficientNet 的預訓練模型在 ImageNet 上達到了比 ResNet 更高的準確度，且使用更少的參數。在 Transfer Learning 方面，EfficientNet 的優勢在於即使在較小的數據集上微調，也能保持高效的學習能力，這對於醫學影像資料集尤其有利。它的預訓練性能良好，對於醫學影像中的細微特徵捕捉具有顯著效果。

## 3. 運算時間與資源需求

**ResNet**：ResNet 雖然較深，但因為殘差結構的設計，使得它的訓練和推理速度相對穩定。對於 Transfer Learning 任務，ResNet 在現有的硬體（如 GPU）上可以高效地進行訓練和微調。如果選擇較淺的版本（如 ResNet-18 或 ResNet-34），可以進一步降低運算成本，同時仍然保持較好的性能。

**EfficientNet**：EfficientNet 的設計優化了運算效率，在相同準確率要求下所需的計算資源比 ResNet 更少。因此，EfficientNet 特別適合在資源有限的情境下使用，比如在醫療設備上進行實時推理。即便是較小版本的 EfficientNet（如 EfficientNet-B0），在保持準確率的同時，也能顯著降低訓練和推理時間，這對於大規模醫學影像分類特別有幫助。

## 綜合分析與結論：

**ResNet** 因其穩定的深層架構和較高的 Transfer Learning 準確性，適合需要高準確率的醫學影像分類，特別是處理較大數據集或需要較深特徵提取的情境。

**EfficientNet** 則因其高效的計算和資源友好的特性，非常適合在資源受限且需要高效處理的場景中使用。它在保持模型性能的同時減少


了計算資源需求，使其非常適合高解析度的醫學影像分類任務。在胸腔 X 光照片分類的 **Transfer Learning** 任務中，**ResNet** 提供了穩定的深層架構，能有效應用於醫學影像分類；而 **EfficientNet** 以其高效能和資源友好特性，成為一個計算量小且表現優異的選擇。這兩個模型在性能和效率上達到了良好的平衡。

## 1.2 Task B: Fine-tuning the ConvNet (30%)

You will fine-tune the selected pre-trained models on our 2-class x-ray dataset. They need to modify the models to fit the new dataset and analyze the effectiveness of fine-tuning, considering the architecture and depth of the networks.

**Discussion (30%, 15% for each):** Analyze the performances of the fine-tuned models. Include a comparative evaluation, focusing on how effectively fine-tuning facilitated their adaptation to the new task.


### Resnet50



Test Accuracy: 82.45%

Test Loss: 0.5599

### EfficientNet B0



Test Accuracy: 88.04%

Test Loss: 0.4422

**EfficientNet B0** 在驗證和測試指標上均優於 **ResNet50**。其穩定的損失和準確率曲線，加上較高的測試準確率和較低的測試損失，顯示出其在微調過程中更能有效適應新任務。這可能是因為 **EfficientNet** 高效的架構設計，能在參數更少的情況下實現高準確率，使其特別適合小數據集或資源有限的任務需求。

總結：

**ResNet50**：存在過擬合的情況，驗證準確率不穩定，表明其在新任務上的適應性較差。


**EfficientNet B0**：展示了穩定且一致的學習曲線，更好的泛化能力以及更高的測試準確率，表明其在新任務上的適應性更佳。

### 1.3 Task C: ConvNet as Fixed Feature Extractor (30%)

You will transform the selected models into fixed feature extractors by freezing all layers except the final one and evaluate their performance.

**Discussion (30%, 15% for each)**: Similar to Task B, provides a comprehensive analysis of the models' performances. The focus should again be on a comparative evaluation of their effectiveness in the new task, though this time as fixed feature extractors.


#### Resnet50



Test Accuracy: 85.05%

Test Loss: 0.3454

#### EfficientNet B0



Test Accuracy: 88.04%

Test Loss: 0.4422

作為固定特徵提取器，EfficientNet B0 在測試準確率和穩定性方面優於 ResNet50。EfficientNet B0 平滑的損失曲線和穩步提升的驗證準確率表明，即使僅微調最後一層，該模型仍具有良好的泛化能力。相較之下，ResNet50 在驗證表現上波動較大，這表示 ResNet50 更依賴於額外可訓練層以達到最佳適應性。

綜合來說，EfficientNet B0 作為固定特徵提取器相比 ResNet50 展現了更好的表現與泛化能力。它在測試準確率上較高，且驗證曲線更為穩定，顯示出它在有限學習條件下更有效地適應新任務。這使得 EfficientNet B0 更適合作為資源受限情況下的新任務選擇。

#### **1.4 Task D: Comparison and Analysis (10%)**

After completing Task B and C, contrast the performance outcomes and adaptability of the models when subjected to the two distinct transfer learning approaches.

**Discussion (10%):** Offer a succinct analysis that highlights the differences in performance and adaptability observed when the models are fine-tuned versus when used as fixed feature extractors.

##### **性能差異：**

在完全微調所有層的情境下，EfficientNet B0 和 ResNet50 都展現出更高的測試準確率與穩定的驗證表現。特別是 EfficientNet B0，在所有層可訓練的情況下，能更有效地學習數據集特徵，達到 88.04% 的測試準確率，表現略優於 ResNet50。

當作為固定特徵提取器時，兩個模型的性能皆有所下降，但 EfficientNet B0 的表現依然優於 ResNet50，顯示出 EfficientNet B0 在預訓練特徵的泛化能力上更為優秀。ResNet50 在僅訓練最後一層時的測試準確率相對較低，說明其在固定特徵提取下的適應性較弱。

##### **適應性差異：**

Fine-tuning 方式允許模型中的所有層進行微調，因此 ResNet50 和 EfficientNet B0 都能更靈活地調整內部特徵以適應新的數據集特性。這在驗證準確率和損失曲線上表現出更高的穩定性與學習效果。

Fixed Feature Extractor 方法限制了大部分層的更新，僅保留最後一層進行訓練，這大大減少了模型適應新數據集的能力。相較於 ResNet50，EfficientNet B0 在這種情境下仍然能保持較高的泛化能力和穩定性，顯示出其架構在僅依賴預訓練特徵時的優勢。

##### **總結：**

整體來看，Fine-tuning 方法下兩個模型均達到較高的性能，並能更



靈活地適應新任務；而在固定特徵提取的情境下，EfficientNet B0 展現出更好的適應性和穩定性，使其在受限的遷移學習環境中成為更適合的選擇。

### **1.5 Task E: Test Dataset Analysis (10%)**

In the original Lab 4's code, you may have encountered challenges in enhancing the performance on the test dataset.

**Discussion (10%):** Elucidate your perspective on this phenomenon. Provide an analysis explaining the reasons behind the difficulty in improving the test dataset performance.

#### **1. 模型結構設計不足**

自行建立的神經網絡結構可能在複雜性和容量上不足，無法捕捉數據中足夠的特徵，導致模型的表現受限。若網絡層數過少或每層神經元數量不足，可能無法有效學習到數據中的深層次特徵，尤其是在處理圖像數據時。

同時，模型架構的選擇（例如卷積層數、池化層設計、全連接層數等）若無法有效適應數據集的特徵，可能會導致學習效果不佳，測試準確率也因此難以提高。

#### **2. 過擬合或欠擬合問題**

如果模型在訓練集上表現良好，但測試集上準確率較低，可能是過擬合的跡象。模型可能過於記住了訓練數據的特徵，導致在測試數據上表現欠佳。這通常發生在模型複雜度過高而數據量不足的情況。

另一方面，若模型在訓練集上的準確率也無法提升到理想水平，則可能是欠擬合，意味著模型的複雜度不足或訓練次數不夠，無法從數據中學習到足夠的特徵。

#### **3. 數據集的限制**

數據集的規模和質量對模型的性能影響很大。若數據集樣本數量不足，模型難以學到具有代表性的特徵，導致泛化能力較差。此外，數據集中可能存在噪音、不平衡或樣本分布不均的問題，這些問題都會影響模型的學習效果。

#### **4. 學習率和訓練過程參數設置**

學習率、批次大小和訓練 epoch 數等超參數也會對模型性能產生影響。學習率過大可能導致模型錯過最佳解，學習率過小則可能導致訓練過慢或陷入局部最小值。批次大小和訓練次數的選擇也會影響模型的收斂效果。因此，適當的超參數調整對提升測試集性能非常重要。